Asistente inteligente de cronogramas

Predicción de retrasos en tareas de proyectos mediante Machine Learning

Documento técnico de investigación · Proyecto final

Sheila De Oleo

Maestría en Inteligencia Artificial, Educación e Investigación
Curso: Machine Learning

Noviembre de 2026

Resumen

Los cronogramas de proyectos suelen construirse con estimaciones subjetivas, y los atrasos se detectan cuando ya ocurrieron. Este trabajo desarrolla un sistema de Machine Learning que estima, en el momento de comprometer una fecha límite, la probabilidad de que una tarea se atrase y la magnitud probable del atraso, y lo integra en un prototipo web para la gestión de cronogramas. Se utilizó un conjunto de datos público de 64,747 tareas reales con fecha límite de ocho organizaciones de software (Choetkiertikul et al., 2017). Se compararon regresión logística, Random Forest y XGBoost mediante validación cruzada temporal. El modelo seleccionado (XGBoost) alcanzó, sobre tareas posteriores al periodo de entrenamiento, un ROC-AUC de 0.95, un PR-AUC de 0.86 y un F1 de 0.76, con probabilidades bien calibradas (Brier = 0.066). La estimación de los días de atraso resultó considerablemente más incierta: el error absoluto mediano bajó de 22 a 15 días frente a la línea base. La interpretación con SHAP identificó como factores principales el historial de atrasos del responsable, la holgura hasta la fecha límite y el nivel de seguimiento de la tarea. El prototipo combina ambos modelos con una simulación Monte Carlo que propaga los atrasos por las dependencias para estimar la probabilidad de cumplir la fecha comprometida, las fechas P50 y P80 y las tareas que conforman el cuello de botella.

Palabras clave: gestión de proyectos, cronogramas, predicción de retrasos, XGBoost, SHAP, simulación Monte Carlo.

1. Planteamiento de la problemática

La gestión de cronogramas es una de las áreas de conocimiento centrales de la dirección de proyectos (Project Management Institute [PMI], 2021). En la práctica, las duraciones se estiman por juicio experto y el seguimiento se basa en el porcentaje de avance reportado, de modo que el riesgo de atraso se vuelve visible tarde, cuando el margen de maniobra es mínimo. Los estudios de la industria del software han documentado durante décadas que una proporción importante de los proyectos se entrega fuera del plazo previsto (The Standish Group, 2015).

Al mismo tiempo, las herramientas de gestión de trabajo (Jira, Azure DevOps, Planner) acumulan un historial detallado de tareas: tipo, prioridad, responsable, dependencias, cambios y fechas. Ese historial permite aprender patrones de atraso y transformar la gestión de cronogramas de una actividad reactiva a una **preventiva**. La pregunta de investigación es:

¿Es posible predecir, en el momento de comprometer una fecha límite, qué tareas de un proyecto se atrasarán y en qué magnitud, y usar esa predicción para estimar la probabilidad de cumplir la fecha final del proyecto?

1.1 Justificación

- **Relevancia práctica:** un gerente de proyecto necesita saber dónde concentrar su atención. Una alerta temprana permite redistribuir carga, renegociar alcance o dar

holgura antes de que el atraso ocurra.

- **Relevancia metodológica:** el problema integra clasificación, regresión, interpretabilidad y simulación, y exige un diseño de validación cuidadoso (temporal, sin fuga de información y con clases desbalanceadas).
- **Vinculación profesional:** la autora se desempeña en gestión de proyectos y facilitación ágil en el sector financiero, donde los compromisos de fecha con el negocio son críticos. El prototipo está diseñado para usarse con cronogramas reales del día a día.

2. Objetivos

2.1 Objetivo general

Desarrollar un modelo de Machine Learning que prediga el riesgo y la magnitud del atraso de las tareas de un proyecto a partir de sus características al momento de asignarles una fecha límite, e integrarlo en un prototipo web que apoye la gestión de cronogramas.

2.2 Objetivos específicos

- Caracterizar un conjunto de datos real de tareas con fecha límite e identificar, mediante análisis exploratorio, los factores asociados al atraso.
- Entrenar y comparar modelos de clasificación (¿se atrasará?) y de regresión (¿cuántos días?) bajo un esquema de validación temporal.
- Evaluar los modelos con métricas adecuadas al desbalance de clases y verificar la calibración de las probabilidades.
- Interpretar las predicciones con valores SHAP para obtener factores de riesgo accionables.
- Implementar un prototipo web que, a partir de un cronograma, simule el proyecto, estime la probabilidad de cumplimiento y priorice las tareas críticas.

3. Descripción y caracterización del conjunto de datos

Se utilizó el conjunto de datos público de Choetkiertikul et al. (2017), disponible en el repositorio *SEAnalytics/datasets* de GitHub. Contiene tareas (*issues*) con fecha límite extraídas de los sistemas JIRA de ocho organizaciones de software de código abierto. Se empleó la versión en la que las variables se midieron **en el momento en que se asignó la fecha límite** a cada tarea. Ese es el instante en que un gerente compromete una fecha en su cronograma, y además garantiza que el modelo no use información del futuro.

Tabla 1. *Composición del conjunto de datos por organización*

Organización	Tareas	% atrasadas	Periodo
Apache	6,289	41.4	2004–2016
Duraspace	3,676	26.4	2007–2015
Java.net	16,326	16.0	2009–2016
JBoss	3,526	53.9	2004–2016
JIRA	4,428	28.4	2004–2015
Moodle	17,004	11.2	2010–2016
Mulesoft	8,269	16.1	2010–2016
WSO2	5,229	23.7	2006–2016
Total	**64,747**	**21.4**	2004–2016

Cada registro incluye 15 variables predictoras, que se tradujeron a lenguaje de gestión de proyectos (Tabla 2), y la variable *delaydays*: los días transcurridos entre la fecha límite y el cierre real de la tarea (0 si se cerró a tiempo). A partir de ella se definieron dos objetivos:

- **atrasada** (binaria): 1 si la tarea se cerró después de su fecha límite. Es el objetivo del modelo de clasificación.
- **días de atraso** (continua): para las tareas atrasadas, cuántos días excedió la fecha límite. Es el objetivo del modelo de regresión.

Tabla 2. *Variables predictoras utilizadas*

Variable	Descripción	Original
Días hasta la fecha límite	Holgura entre el compromiso y la fecha límite	RemainingDay
Días desde la creación	Antigüedad de la tarea al comprometer la fecha	ProgressTime
Carga del responsable	Tareas abiertas asignadas al responsable	workload
% atrasos del responsable	Porcentaje histórico de tareas atrasadas del responsable	perofdelay
Predecesoras / Tareas que bloquea	Dependencias en ambas direcciones	no_blockedby / no_blocking
Tareas relacionadas	Total de vínculos con otras tareas	no_issuelink
Reaperturas	Veces que la tarea se reabrió (retrabajo)	repetition
Comentarios	Comentarios registrados	no_comment
Cambios de prioridad / alcance	Cambios de prioridad y de descripción	no_priority_change / no_des_change
Entregas asociadas / Replanificaciones	Versiones asignadas y cambios de versión	no_fixversion / no_fixversion_change
Días de definición	Tiempo de discusión de la solución	discussion
Tipo y prioridad	9 tipos agrupados; prioridad ordinal 1–5	type / priority

El conjunto presenta un **desbalance moderado**: el 21.4 % de las tareas se atrasó (Figura 1). La distribución de los días de atraso es muy asimétrica: mediana de 25 días, percentil 90 de 205 días y máximo de 1,169 días.

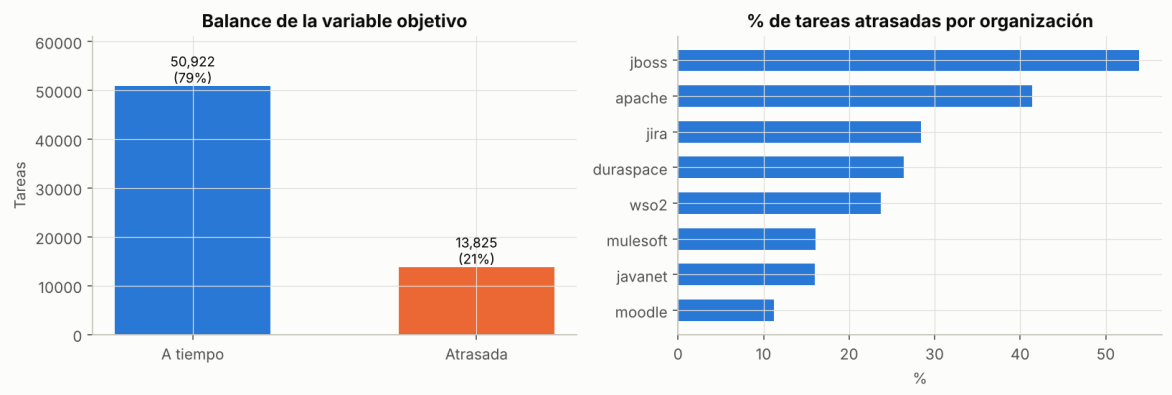


Figura 1. *Balance de la variable objetivo y tasa de atraso por organización.*

4. Metodología de desarrollo

El proyecto siguió el proceso CRISP-DM (Chapman et al., 2000): comprensión del problema, comprensión de los datos, preparación, modelado, evaluación y despliegue. Todo el código se implementó en Python con pandas, scikit-learn (Pedregosa et al., 2011), XGBoost (Chen & Guestrin, 2016), SHAP (Lundberg & Lee, 2017) y Streamlit. El cuaderno de trabajo documenta cada etapa y es reproducible de principio a fin.

4.1 Calidad y preprocesamiento de datos

- **Valores nulos:** solo la prioridad presentó vacíos (2,292 registros, 3.5 %), imputados con el nivel medio (3).
- **Valores imposibles:** el 3.7 % de los registros tenía un porcentaje de atrasos del responsable mayor a 100; se recortaron al rango [0, 100].
- **Categorías:** los 44 tipos de tarea se agruparon en 9 categorías y las prioridades de distintas escalas se homologaron a una escala ordinal de 1 a 5.
- **Variables excluidas:** los temas LDA de la descripción (*topic_**), porque no pueden calcularse sobre un cronograma nuevo sin el modelo de temas original.
- **Transformaciones:** codificación *one-hot* del tipo de tarea. Para los modelos lineales, log(1+x) y estandarización de los conteos asimétricos; los modelos de árboles no requieren escalado.
- **Sin duplicados:** no se encontraron registros repetidos.

4.2 Análisis exploratorio

El análisis exploratorio (Figura 2) reveló relaciones relevantes para la gestión de proyectos:

- Las tareas comprometidas con 0 a 1 día de holgura se atrasan hasta en un 77 % de los casos, frente a un 21 % promedio.

- Los responsables con más del 50 % de atrasos históricos vuelven a atrasarse en el 70 % de los casos.
- **Resultado contraintuitivo:** las tareas que nunca se replanificaron se atrasan más (41 %) que las replanificadas (cerca del 7 %), y los responsables con muy pocas tareas abiertas se atrasan más que los de carga media. La interpretación es que la replanificación y la carga son **indicadores de seguimiento activo y de compromiso con el proyecto**, no causas de puntualidad. Las tareas sin actividad son las que se olvidan.

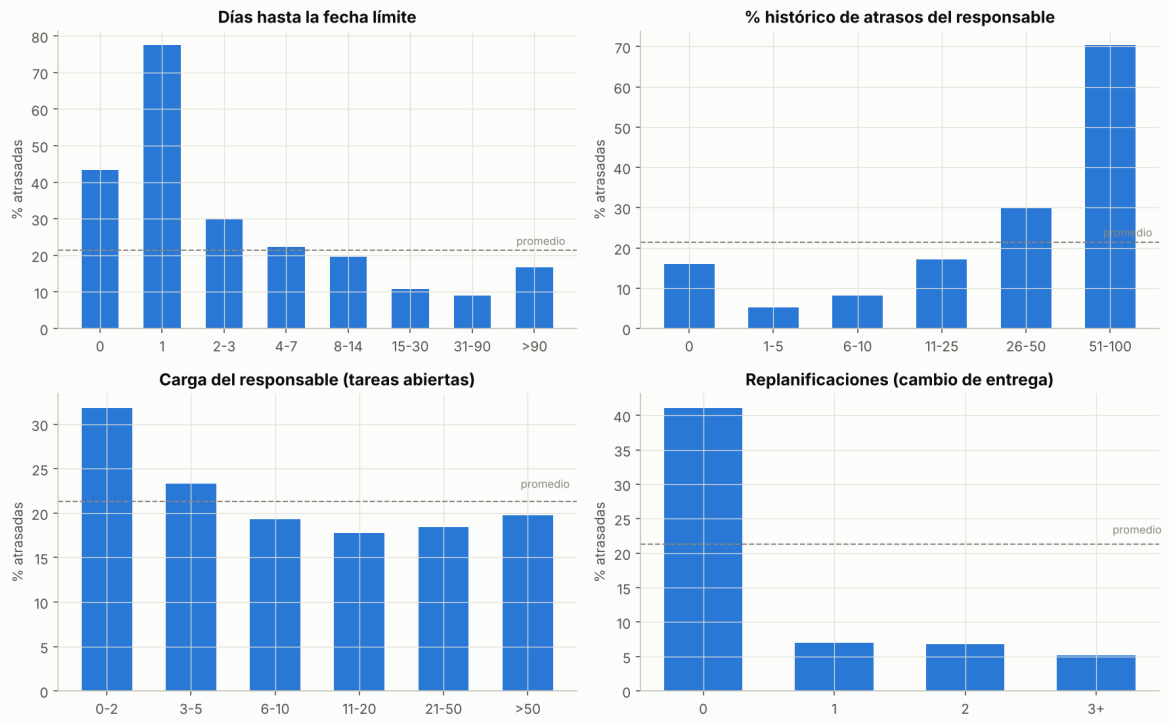


Figura 2. *Porcentaje de tareas atrasadas según holgura, historial y carga del responsable, y replanificaciones. La línea punteada marca el promedio general.*

4.3 Diseño de validación

Como el sistema se usará para predecir tareas futuras, se aplicó una **partición temporal**: las tareas se ordenaron por fecha de creación; el 80 % más antiguo (51,797 tareas, 2004–2014) se usó para entrenamiento y el 20 % más reciente (12,950 tareas, 2014–2016) para la prueba final. Dentro del entrenamiento, los modelos se compararon mediante **validación cruzada temporal** de 4 particiones (*TimeSeriesSplit*), en la que cada partición entrena con el pasado y valida con el periodo siguiente. El conjunto de prueba solo se usó una vez, para la evaluación final.

5. Selección y fundamentación de los modelos

Tabla 3. *Modelos comparados*

Modelo	Tipo	Fundamentación
Regresión logística / Ridge	Lineal	Línea base interpretable; permite verificar si hay relaciones no lineales que justifiquen modelos más complejos.
Random Forest	Ensamble (bagging)	Combina cientos de árboles entrenados con muestras aleatorias; captura interacciones no lineales y es robusto al ruido (Breiman, 2001).
XGBoost	Ensamble (boosting)	Construye árboles secuenciales que corrigen los errores de los anteriores, con regularización; es el estado del arte en datos tabulares (Chen & Guestrin, 2016).
Línea base trivial	Referencia	Clase mayoritaria (clasificación) y mediana histórica (regresión): el mínimo que un modelo útil debe superar.

Se plantearon dos modelos complementarios cuya combinación produce el **atraso esperado** de cada tarea:

$$\textit{Atraso esperado} = P(\textit{atraso}) \times \textit{días estimados de atraso si ocurre}$$

No se usó ponderación de clases ni sobremuestreo. En su lugar se ajustó el umbral de decisión, para conservar probabilidades **calibradas** (Niculescu-Mizil & Caruana, 2005). Esto es indispensable porque el prototipo usa esas probabilidades directamente en la simulación del cronograma. El modelo de regresión se entrenó sobre log(1 + días) para reducir la influencia de los atrasos extremos.

Métricas de evaluación

- **Clasificación:** ROC-AUC (capacidad de ordenar por riesgo), PR-AUC (más informativa con clases desbalanceadas; Saito & Rehmsmeier, 2015), precisión, recall, F1, exactitud y puntaje de Brier (calibración).
- **Regresión:** MAE, error absoluto mediano (MedAE, robusto a extremos), RMSE, R^2 en escala logarítmica y correlación de Spearman (capacidad de ordenar).

6. Entrenamiento, validación y evaluación

6.1 Modelo de clasificación

Tabla 4. *Validación cruzada temporal (promedio de 4 particiones)*

Modelo	ROC-AUC	PR-AUC	F1 (umbral 0.5)
Random Forest	0.902	0.752	0.649
Regresión logística	0.852	0.585	0.546
XGBoost	0.903	0.757	0.661

XGBoost obtuvo el mayor PR-AUC promedio y fue seleccionado; Random Forest quedó prácticamente empatado. Ambos superan claramente a la regresión logística, lo que confirma relaciones **no lineales**: por ejemplo, el riesgo no disminuye de forma proporcional con la holgura, sino que se dispara cuando quedan 0–1 días. El umbral de decisión se ajustó a **0.61** maximizando F1 en la partición de validación más reciente. La

Tabla 5 muestra la evaluación final sobre el conjunto de prueba.

Tabla 5. *Evaluación final de clasificación en el conjunto de prueba (tareas 2014–2016)*

Modelo	Umbral	ROC-AUC	PR-AUC	Exact.	Precisión	Recall	F1	Brier
Línea base	0.50	0.500	0.200	0.800	0.000	0.000	0.000	0.160
Regresión logística	0.50	0.906	0.735	0.879	0.701	0.692	0.696	0.094
Random Forest	0.50	0.952	0.858	0.913	0.799	0.756	0.777	0.067
XGBoost	0.61	0.951	0.859	0.913	0.837	0.698	0.761	0.066

Nota. La línea base alcanza 80 % de exactitud sin detectar ningún atraso (recall = 0), lo que muestra por qué la exactitud es engañosa con clases desbalanceadas.

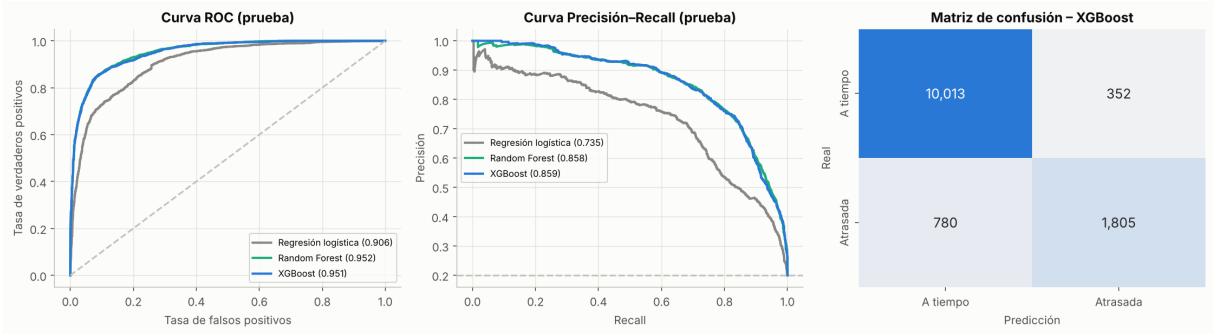


Figura 3. *Curvas ROC y Precisión-Recall de los tres modelos y matriz de confusión de XGBoost en el conjunto de prueba.*

Con el umbral seleccionado, XGBoost tiene una precisión de 0.84: de cada 100 tareas que marca como riesgo, unas 84 efectivamente se atrasan. Su recall es de 0.70, es decir, anticipa cerca del 70 % de los atrasos reales. Si se prefiere detectar más atrasos a costa de más falsas alarmas, el umbral puede bajarse. La curva de calibración (Figura 4) muestra que las probabilidades del modelo se aproximan a las frecuencias observadas, lo que valida su uso en la simulación.

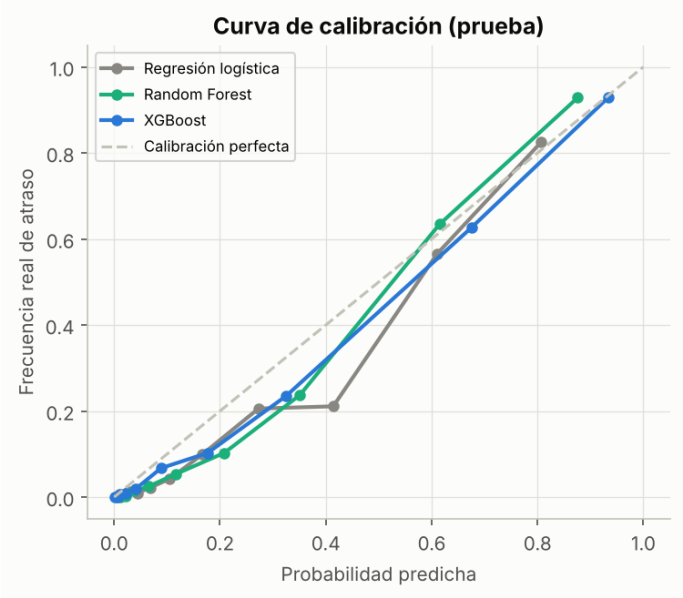


Figura 4. *Curva de calibración en el conjunto de prueba.*

6.2 Modelo de regresión

Tabla 6. *Evaluación de regresión en el conjunto de prueba (solo tareas atrasadas)*

Modelo	MAE (días)	MedAE (días)	RMSE (días)	R^2 (log)	Spearman
Línea base (mediana)	32.1	22.0	51.5	0.000	—
Ridge	30.1	17.3	50.9	0.033	0.268
Random Forest	30.0	14.6	51.6	0.074	0.397
XGBoost	28.0	14.2	49.8	0.134	0.448

Predecir **cuántos** días se atrasará una tarea es mucho más difícil que predecir **si** se atrasará. En la validación cruzada temporal, los modelos apenas superaron a la línea base (error mediano cercano a 24 días en todos los casos), y Random Forest fue el seleccionado por menor MedAE. En el conjunto de prueba la mejora fue mayor: el MedAE bajó de 22 a 14.6 días y la correlación de Spearman fue de 0.40. XGBoost obtuvo un desempeño ligeramente superior en la prueba, pero se respetó la selección hecha por validación cruzada para no ajustar decisiones al conjunto de prueba. El R^2 bajo indica que la magnitud del atraso depende en gran medida de factores ausentes en los datos (cambios de prioridad del negocio, ausencias, dependencias externas).

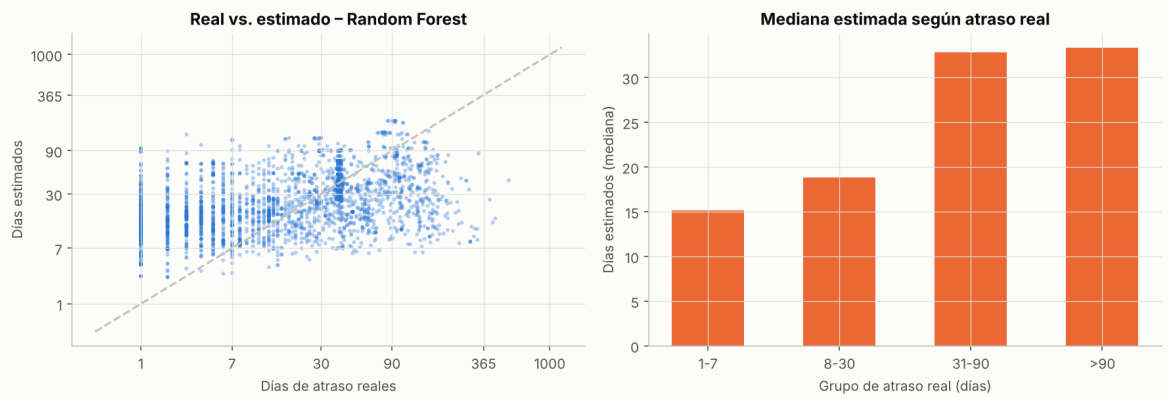


Figura 5. *Días de atraso reales frente a estimados (escala logarítmica) y mediana estimada por grupo de atraso real.*

7. Resultados y análisis

7.1 Interpretación del modelo: factores de riesgo

Los valores SHAP (Lundberg & Lee, 2017) descomponen cada predicción en la contribución de cada variable. La Figura 6 resume el efecto sobre 3,000 tareas del conjunto de prueba.

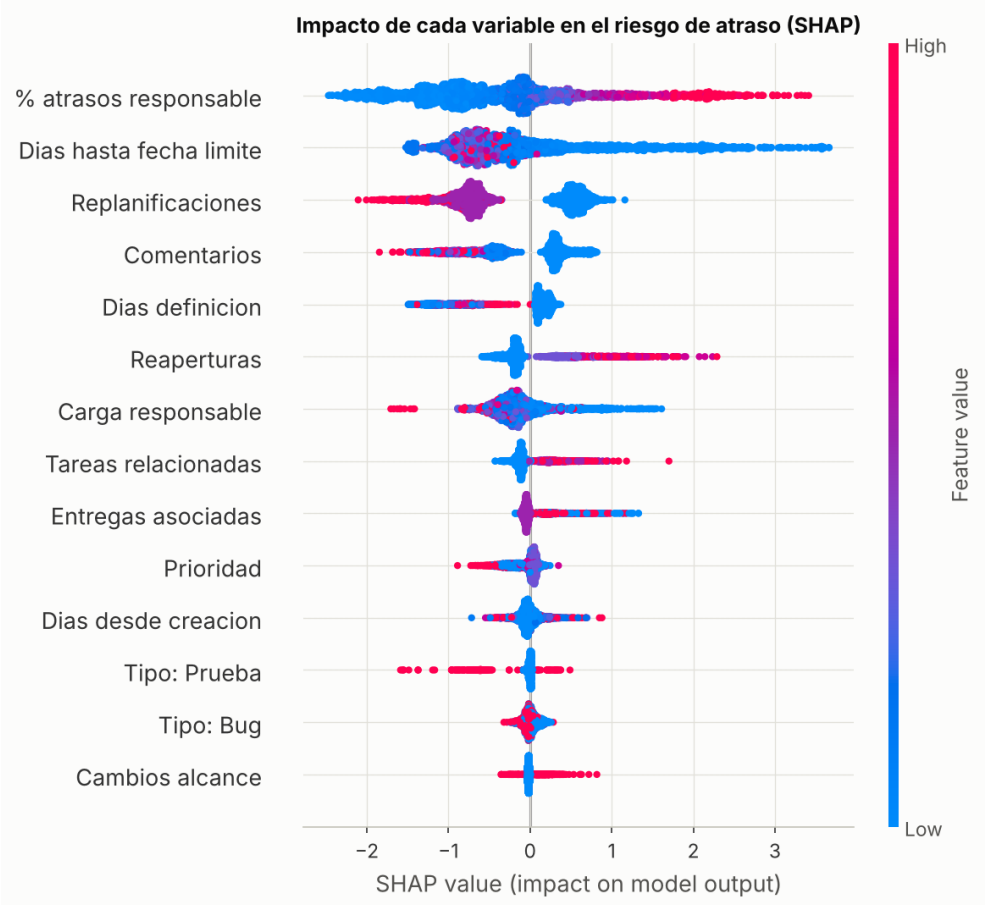


Figura 6. *Resumen SHAP: cada punto es una tarea; el color indica el valor de la variable (rojo alto, azul bajo) y la posición horizontal, su efecto sobre el riesgo de atraso.*

- **% histórico de atrasos del responsable:** es el factor más influyente. Más que evaluar a la persona, señala patrones de sobrecompromiso o de estimación que conviene abordar con coaching y ajuste de carga.
- **Días hasta la fecha límite:** la falta de holgura incrementa fuertemente el riesgo.
- **Replanificaciones, comentarios y días de definición:** valores altos **reducen** el riesgo. Una tarea silenciosa, sin seguimiento, es una señal temprana de abandono.
- **Reaperturas:** el retrabajo, uno de los desperdicios descritos por Lean, aumenta el riesgo de atraso.
- **Dependencias y vínculos:** más relaciones implican más coordinación y más riesgo.

7.2 Robustez entre organizaciones

El ROC-AUC en el conjunto de prueba varió entre organizaciones: fue alto en Moodle (0.99), Duraspace (0.97) y WSO2 (0.96), y menor en Apache (0.75) y JBoss (0.67), cuyos periodos de prueba tienen tasas de atraso inusualmente altas (65–70 %) y menos tareas. JIRA aportó solo 6 tareas al periodo de prueba, por lo que su resultado no es concluyente. Esta heterogeneidad respalda la decisión de diseño de permitir que cada equipo aporte su propio historial (por ejemplo, el porcentaje de atrasos de cada responsable calculado a partir de sus tareas cerradas) y de ofrecer un factor de ajuste al contexto.

8. Prototipo inteligente: aplicación web

Los modelos se integraron en una aplicación desarrollada en Streamlit, organizada en cinco secciones: (1) presentación del proyecto y de la problemática, (2) análisis de un cronograma, (3) evaluación de una tarea individual, (4) resultados del modelo y (5) metodología y limitaciones.

El análisis de un cronograma sigue cuatro pasos:

- **Carga:** el usuario sube un archivo Excel o CSV con una plantilla sencilla (tarea, tipo, prioridad, responsable, fechas, predecesoras y estado), o edita el cronograma de ejemplo directamente en la aplicación.
- **Cálculo de variables:** el sistema traduce el cronograma a las variables del modelo. Calcula la holgura según la fecha de corte, la carga de cada responsable, las dependencias abiertas y el historial de atrasos a partir de las tareas cerradas. Este historial se suaviza con un promedio bayesiano para que una sola tarea atrasada no implique un 100 %. Los datos de seguimiento no registrados se completan con valores típicos.
- **Simulación Monte Carlo:** en cada uno de 2,000 escenarios, cada tarea abierta se atrasa con la probabilidad del modelo y, si lo hace, en una cantidad de días muestreada alrededor de la estimación del regresor. Los atrasos se propagan a las tareas dependientes. Se obtienen la probabilidad de cumplir la fecha comprometida, las fechas P50 y P80 y un índice de criticidad: el porcentaje de escenarios en que cada tarea forma parte de la cadena que determina la fecha final. Este enfoque probabilístico

es coherente con las prácticas de pronóstico ágil (Vacanti, 2015).

- **Priorización:** las tareas se ordenan por atraso esperado × peso en la ruta crítica, de modo que el cuello de botella aparece primero, acompañado de una explicación SHAP individual.

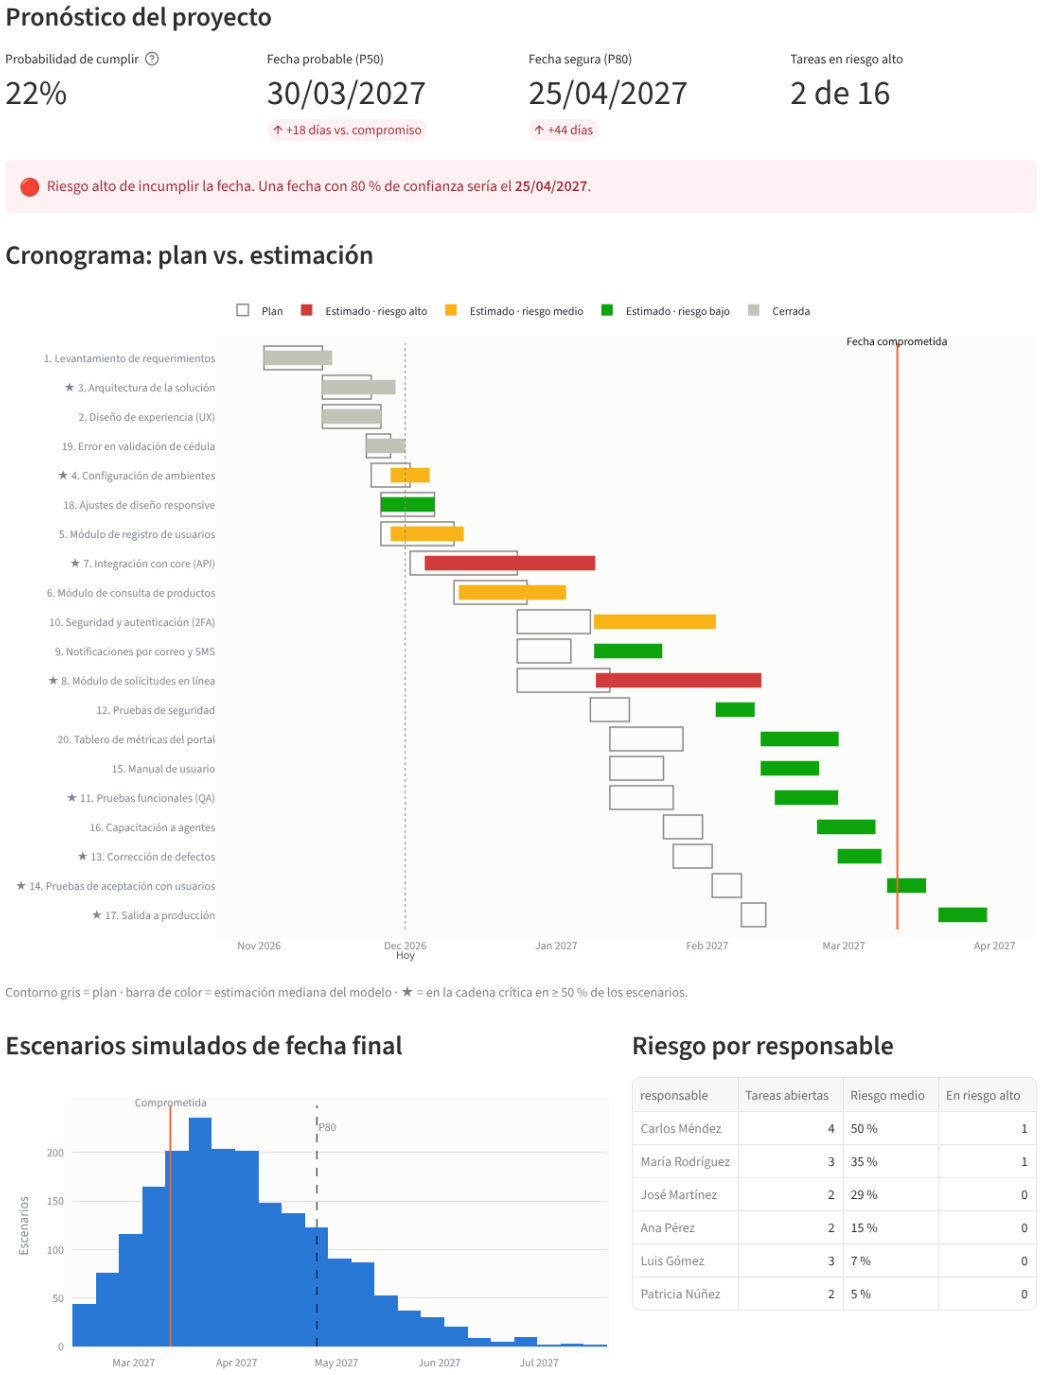


Figura 7. *Pronóstico del proyecto en la aplicación: indicadores, cronograma plan vs. estimación coloreado por nivel de riesgo y tareas en la cadena crítica (★).*

En el cronograma de ejemplo (un portal de autogestión para clientes, con 20 tareas y 6 responsables), el plan termina el 12/02/2027 y la fecha comprometida es el 12/03/2027.

Aun con cuatro semanas de holgura, la probabilidad de cumplir es de aproximadamente 22 %. La cadena formada por la *integración con el core* (90 % de riesgo, presente en la cadena crítica en el 95 % de los escenarios) y el *módulo de solicitudes en línea* constituye el cuello de botella, y es donde el gerente debería concentrar sus acciones. La aplicación también permite evaluar una tarea antes de comprometer su fecha (Figura 8) y sugiere acciones cuando el riesgo es alto.



Figura 8. *Evaluación de una tarea individual con indicador de riesgo y explicación de los factores.*

Por su diseño, la aplicación procesa los archivos en memoria y no los almacena. Para cronogramas con información sensible se documenta su ejecución local.

9. Discusión y limitaciones

- **Transferencia de dominio:** los datos provienen de proyectos de software de código abierto, cuya dinámica (colaboradores voluntarios, plazos largos) difiere de la de un proyecto corporativo. Por eso las predicciones deben considerarse **orientativas** fuera de ese dominio y recalibrarse con el historial propio. Por la misma razón, la aplicación incluye un factor de ajuste de magnitudes y un control de incertidumbre.
- **Magnitud del atraso:** el modelo de regresión aporta una mejora modesta. El prototipo lo compensa comunicando rangos (P50/P80) en lugar de una fecha única, y la incertidumbre de la simulación se acotó (recorte en ±1.5 desviaciones y máximo de 180 días por tarea) para evitar escenarios irreales.

- **Correlación y causalidad:** algunas relaciones, como más replanificaciones con menos atraso, son asociaciones que reflejan el nivel de seguimiento y no deben interpretarse como causas.
- **Independencia entre tareas:** la simulación supone que los atrasos de tareas distintas son independientes salvo por las dependencias explícitas; en la realidad pueden compartir causas comunes, como un mismo proveedor o un recurso compartido.

10. Conclusiones

- Es posible anticipar con alta capacidad discriminativa (ROC-AUC = 0.95 sobre tareas futuras) qué tareas de un cronograma se atrasarán, usando solo información disponible al momento de comprometer la fecha.
- Los ensambles de árboles superan a los modelos lineales, lo que evidencia relaciones no lineales entre los factores de riesgo y el atraso.
- Estimar la magnitud del atraso es considerablemente más incierto. La respuesta de diseño adecuada es comunicar el riesgo de forma probabilística y no como una fecha determinista.
- La interpretación SHAP produce factores de riesgo accionables para la gestión: holgura de las fechas, historial y carga del responsable, retrabajo, dependencias y nivel de seguimiento.
- El prototipo cierra el ciclo *datos* → *modelo* → *prototipo* → *solución*: transforma un cronograma en un pronóstico con probabilidad de cumplimiento, identifica el cuello de botella y prioriza la atención del gerente.

Trabajo futuro: reentrenar el modelo con el historial de la propia organización, incorporar el texto de las tareas mediante procesamiento de lenguaje natural, modelar dependencias entre los atrasos de tareas que comparten recursos e integrar la aplicación directamente con Jira, Azure DevOps o Microsoft Planner.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Choetkiertikul, M., Dam, H. K., Tran, T., & Ghose, A. (2015). Characterization and prediction of issue-related risks in software projects. En *Proceedings of the 12th Working Conference on Mining Software Repositories* (pp. 280–291). IEEE. https://doi.org/10.1109/MSR.2015.33

Choetkiertikul, M., Dam, H. K., Tran, T., & Ghose, A. (2017). Predicting the delay of issues with due dates in software projects. *Empirical Software Engineering, 22*(3), 1223–1263. https://doi.org/10.1007/s10664-016-9496-7

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). Curran Associates.

Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. En *Proceedings of the 22nd International Conference on Machine Learning* (pp. 625–632). ACM. https://doi.org/10.1145/1102351.1102430

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Project Management Institute. (2021). *A guide to the project management body of knowledge (PMBOK guide)* (7.ª ed.). Project Management Institute.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

The Standish Group. (2015). *CHAOS report 2015*. The Standish Group International.

Vacanti, D. S. (2015). *Actionable agile metrics for predictability: An introduction*. Daniel S. Vacanti, Inc.

Anexos

El código fuente, el cuaderno de trabajo (*notebooks/01_prediccion_retrasos_cronogramas.ipynb*), los modelos entrenados, la aplicación web y el video de presentación están disponibles en el repositorio GitHub del

proyecto. El README describe las instrucciones de ejecución.